IMPLEMENTASI WEB SCRAPING PADA PORTAL BERITA ONLINE

Y. A. Hafiz[1], Endah Sudarmilah[2]
[1,2]Informatika, Fakultas Komunikasi dan Informatika, Universitas Muhammadiyah Surakarta
Email: l200200107@student.ums.ac.id

Artikel dikirim : 5 Agustus 2023 Direvisi : 10 Oktober 2023 Diterima : 28 Oktober 2023

ABSTRACT

This report discusses the use of web scraping on several well-known online news portals in Indonesia, such as CNBC Indonesia, CNN Indonesia, Kompas, Merdeka, Suara, Jawapos, JPNN, Republika, and Inews. Web scraping is used as a method to collect data from web pages automatically and efficiently. The web scraping process is carried out using the Visual Studio Code application with the Python programming language and the beautifulsoup library. This web scraping method is divided into several stages, starting from opening the scraping template, determining the website from which the data will be collected, exploring and navigating the site to identify the important elements that you want to retrieve, to running the web scraping and generating the desired data. The results of web scraping are in the form of media, titles, subtitles, news URLs, content, news dates, news editors, news journalists, and news locations. Through the implementation of web scraping, this research concludes several important things. First, web scraping helps simplify the process of collecting data from various news sources and combining them into one easily accessible place. Second, with web scraping, data analysis can be done more quickly and efficiently than manual collection methods. Finally, the results of web scraping can be used to see trends and patterns and analyze public sentiment towards news and certain topics, providing valuable insights for people's understanding of current issues.

Keyword: *BeautifulSoup, Online News Portal, Python, Web Scraping.*

ABSTRAK

Laporan ini membahas tentang penggunaan web scraping pada beberapa portal berita online ternama di Indonesia, seperti CNBC Indonesia, CNN Indonesia, Kompas, Merdeka, Suara, Jawapos, JPNN, Republika, dan Inews. Web scraping digunakan sebagai metode untuk mengumpulkan data dari halaman web secara otomatis dan efisien. Proses web scraping ini dilakukan dengan menggunakan aplikasi Visual Studio Code dengan bahasa pemrograman Python dan library beautifulsoup. Metode web scraping ini dibagi menjadi beberapa tahapan, dimulai dari membuka template scraping, menentukan situs web yang akan diambil datanya, eksplorasi dan navigasi situs untuk mengidentifikasi elemen-elemen penting yang ingin diambil, hingga menjalankan web scraping dan menghasilkan data yang diinginkan. Hasil web scraping berupa Media, Judul, Sub judul, URL berita, Isi konten, Tanggal berita, Editor berita, Jurnalis berita, dan Lokasi berita. Melalui implementasi web scraping, penelitian ini menyimpulkan beberapa hal penting. Pertama, web scraping membantu mempermudah proses pengumpulan data dari berbagai sumber berita dan menggabungkannya menjadi satu tempat yang mudah diakses. Kedua, dengan web scraping, analisis data dapat dilakukan lebih cepat dan efisien daripada metode pengumpulan manual. Terakhir, hasil dari web scraping dapat digunakan untuk melihat tren dan pola serta menganalisis sentimen publik terhadap berita dan topik tertentu, memberikan wawasan yang berharga bagi pemahaman masyarakat terhadap isu-isu terkini.

Kata kunci: BeautifulSoup, Portal Berita Online, Python, Web Scraping.

PENDAHULUAN

Informasi semakin pesat dan penting seiring dengan semakin canggihnya era digital (Fathir et al., 2023). Portal berita online adalah salah satu sumber informasi yang dapat memberikan manfaat tersendiri bagi masyarakat terutama dari sisi akses yang mudah (Arisandi et al., 2021). Berbagai macam berita tentang subjek termasuk politik, ekonomi, teknologi, olahraga, dan lainnya tersedia di platform berita internet (Fikri et al., 2022).

Artikel berita dapat menjadi sumber yang berguna untuk analisis dan studi saat mengumpulkan data. Namun, akan membutuhkan banyak waktu dan upaya untuk mengumpulkan informasi secara manual dari setiap berita yang pernah diterbitkan. Maka dari itu, kita memerlukan teknik yang efektif untuk mengumpulkan artikel berita secara otomatis (Hari et al., 2020).

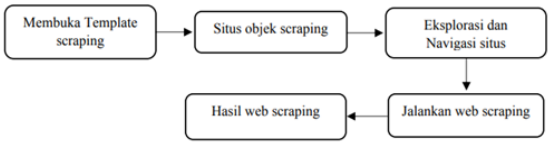
Sebuah metode untuk mengambil data secara otomatis dari halaman web disebut web scraping (Satriajati et al., n.d.). Web Scraping adalah metode untuk mengekstraksi data dari Worldwide Web (WWW) dan menyimpannya ke sistem file atau database untuk pengambilan atau analisis selanjutnya. Biasanya bisa juga disebut sebagai web extraction atau web harvesting (Zhao, 2017). Web Scraping telah diterapkan dalam berbagai bidang sebagai alat bantu untuk pengambilan data seperti analisis topik penelitian kesehatan indonesia pada jurnal sinta (Keputusan Dirjen Penguatan Riset dan Pengembangan Ristek Dikti et al., 2017) dan juga penerapan web scraping pada marketplace indonesia (Sembiring et al., 2020).

Tujuan utama laporan kerja praktek ini adalah untuk menjelaskan bagaimana web scraping dipraktikkan di website artikel berita dan keuntungan melakukannya untuk pengumpulan dan analisis data. Web Scraping memungkinkan penulis dengan cepat dan mudah mengambil sejumlah besar artikel berita, memfasilitasi penyelidikan dan analisis data yang lebih mendalam.

Laporan kerja praktek ini diharapkan bisa memberikan pemahaman kepada pembaca tentang bagaimana web scraping digunakan dalam artikel situs web berita dan pentingnya pengumpulan dan analisis data

METODE PENELITIAN

Proses melakukan web scraping pada situs portal berita online ini menggunakan aplikasi Visual Studio Code dengan Python dan library BeautifulSoup. Library Python yang disebut BeautifulSoup digunakan untuk mengekstrak, memeriksa, dan mengubah data dari pohon DOM situs web yang didasarkan pada pengembangan mesin analisis HTML dan XML (Julianno et al., n.d.). Pada penerapannya, web scraping ini dibagi menjadi beberapa tahapan seperti pada Gambar 1 di bawah ini.



Gambar 1 Metode Web Scraping

Membuka Template Scraping

Pada tahapan pertama ini kita membuka template yang sudah disiapkan. Template ini berisi code python yang berfungsi untuk pengambilan data atau melakukan web scraping pada portal berita online.

Situs Objek Scraping

Selanjutnya kita menentukan situs web mana yang ingin kita ambil datanya atau ingin kita lakukan web scraping. Pastikan situs web tersebut memiliki struktur yang konsisten dan memungkinkan akses ke artikel berita secara terbuka. Pada kasus ini kita menggunakan situs web berita online yang sudah ternama di Indonesia, yaitu CNBC Indonesia, CNN Indonesia, Kompas, Merdeka, Suara, Jawapos, JPNN, Republika, dan Inews.

Eksplorasi dan Navigasi Situs

Tahapan ketiga ini kita perlu mengeksplorasi situs web yang ingin kita scraping untuk memahami cara situs tersebut mengorganisir konten berita. Gunakan fitur "Inspect" pada browser web (biasanya dengan mengklik kanan pada elemen dan memilih opsi Inspect) untuk melihat kode HTML dan CSS yang membentuk halaman situs web. Lalu kita Identifikasi elemen-elemen penting seperti judul, penulis, tanggal, isi artikel, dan informasi lain yang ingin kita ambil (Deviacita et al., 2019). Kemudian elemen elemen pada kode html tersebut kita masukkan kedalam template scraping. Seperti contoh kita mengambil elemen indeks berita pada situs Inews pada Gambar 2 di bawah ini.

```
#TODO #1
#container berisi indeks berita
indeks_container = soup.find(
        attrs={'class': 'list-unstyled news-update-inews'})
#list dari berita di indeks tsb
articles = indeks_container.findAll(
        attrs={'class': 'padding-10px-all'})
```

Gambar 2 Contoh mengambil elemen berita

Jalankan Web Scraping

Setelah kita selesai melakukan penyesuaian kode terhadap situs web yang akan di scraping dengan menentukan situs web, kemudian memasukkan elemen elemen pada situs web kedalam template scraping, selanjutnya kita mulai lakukan web scraping. jalankan code pada template web scraping tersebut, maka hasil scraping akan keluar nantinya.

Hasil Web Scraping

Tahapan terakhir yaitu hasil dari web scraping. Setelah semua tahapan dilakukan dan kode sudah dijalankan maka hasil dari web scraping akan keluar sesuai dengan elemen elemen yang ingin kita ambil dari situs web tersebut. Kemudian juga hasil web scraping akan di export menjadi file csv sehingga bisa diakses dengan mudah.

HASIL DAN PEMBAHASAN

Berdasarkan Metode yang telah diimplementasikan, Hasil yang dibutuhkan yaitu Media, Judul, Sub judul, URL berita, Isi content, Tanggal berita, Editor berita, Jurnalis berita, Lokasi berita. Berikut hasil dari Implementasi Web scraping pada beberapa portal berita online ternama.

Hasil Web Scraping CNBC

CNBC Indonesia merupakan salah satu portal berita online ternama di Indonesia. CNBC Indonesia menyampaikan informasi-informasi, makro ekonomi, pasar modal, perbankan, industri keuangan lainnya, komoditas, manufaktur, ekonomi internasional serta politik, hukum dan hankam yang mempengaruhi dinamika ekonomi nasional secara komprehensif. Scraping pada CNBC diambil dari sub News, sehingga berita yang diambil merupakan berita terbaru. Hasil scraping CNBC seperti pada Gambar 3.

Judul	URL	Tanggal	Media	Author	Lokasi	Content	Sub
Buruh Minta UMP & UMK 2024 Naik Maksimal 15%, Ini Hitungannya	https://www.cnbcindonesia.com/news/20230722193554-4-456454/buruh-minta-ump-umk-2024-naik-maksimal-15-ini-hitungannya	2023-07-22 21:40:00	cnbc	Romys Binekasri	Jakarta	Jakarta, CNBC Indonesia - Presiden Partai Buruh yang juga Presiden Konfederasi Serikat Pekerja Indonesia (KSPI) Said Iqbal meminta pemerintah menaikkan upah minimum provinsi (UMP) dan upah minimun kabupaten/kota (UMK) tahun 2024 sebesar 15%.	news

Gambar 3 Hasil Web Scraping CNBC Indonesia

Hasil Web Scraping CNN

Pada portal berita online CNN Indonesia, scraping diambil dari sub Nasional karena artikel berita di CNN Indonesia tidak hanya berita dalam negeri namun juga mereka memberitakan berita Internasional sehingga disini data yang kita ambil hanya dari berita Nasional. Lebih spesifik lagi pada sub Nasional terdapat segmen politik dan berita dari segmen politik tersebut yang diambil pada CNN Indonesia. Output yang dihasilkan yaitu pada Gambar 4 di bawah ini.

Judul	URL	Tanggal	Media	Author	Lokasi	Content	Sub
Ganjar Dampingi Jokowi dan Ma'ruf Amin Besok: Nasib Jadi Bawahan	https://www.cnnindonesia.com/nasional/20230722223821-32-976587/ganjar-dampingi-jokowi-dan-maruf-amin-besok-nasib-jadi-bawahan	2023-07-22 23:02:00	cnn	CNN Indonesia	Jakarta	Jakarta, CNN Indonesia - Gubernur Jawa Tengah sekaligus bakal calon presiden (Bacapres) PDIP Ganjar Pranowo bercerita dirinya akan mendampingi Presiden Joko Widodo (Jokowi) dan Wakil Presiden Ma'ruf Amin dalam kegiatan di Jawa Tengah pada Minggu (23/7) besok.	nasional

Gambar 4 Hasil Web Scraping CNN Indonesia

Hasil Web Scraping Kompas

Scraping pada Kompas.com hampir sama dengan CNN Indonesia, berita yang diambil merupakan berita dari sub Nasional karena pada Kompas.com terdapat juga berita global sehingga kita hanya mengambil berita Nasional. Gambar 5 di bawah ini merupakan hasil dari scraping kompas.com.

Judul	URL	Tanggal	Media	Author	Lokasi	Content	Sub
Pesan Panglima TNI ke Prajurit Jelang Pemilu 2024: Harus Peka dan Antisipatif terhadap Dinamika	https://nasional.kompas.com/read/2023/10/17/16081231/pesan-panglima-tni-ke-prajurit-jelang-pemilu-2024-harus-peka-dan-antisipatif	2023-10-17 16:08:00	kompas	Nirmala Maulana Achmad , Bagus Santosa	Jakarta	JAKARTA, KOMPAS.com - Panglima TNI Laksamana Yudo Margono memberikan pesan kepada prajurit menjelang digelarnya pemilihan umum (Pemilu) 2024.	Nasional

Gambar 5 Hasil Web Scraping Kompas.com

Hasil Web Scraping Republika

Republika merupakan portal berita yang sudah cukup lama berdiri. Pada Republika berita diambil dari sub Politik, sehingga berita yang diambil merupakan

berita berita politik terbaru di tanah air. Scraping yang dihasilkan yaitu Media, Judul, Sub judul, URL berita, Isi content, Tanggal berita, Editor berita, Jurnalis berita, dan Lokasi berita seperti yang terlihat pada Gambar 6 di bawah ini

Judul	URL	Tanggal	Media	Author	Lokasi	Content	Sub
Tak Undang Bacapres ke Harlah, PKB Tegaskan Capresnya Muhaimin Iskandar	https://news.republika.co.id/berita/ry6ihl385/tak-undang-bacapres-ke-harlah-pkb-tegaskan-capresnya-muhaimin-iskandar	2023-07-22 10:46:00	jawapos	Muhammad Subarkah	Jakarta	REPUBLIKA.CO.ID, JAKARTA -- Partai Kebangkitan Bangsa (PKB) besok Ahad pagi (23/07/2023) akan menggelar peringatan hari lahir (harlah ke-25 di Stadion Manahan, Solo, Jawa Tengah (Jateng).	politik

Gambar 6 Hasil Web scraping Republika

KESIMPULAN

Simpulan

Diava anti ketombe merupakan salah satu hasil alternatif pemanfaatan daun jambu biji. dalam proses pembuatan dilakukan dengan memcampurkan daun jambu biji dengan bahan lain yang besifat alami. Hasil Diava anti ketombe dengan perlakuan A1 yang memiliki hasil organoleptik mempuyai warna coklat, beraroma khas berbentuk cair agak kental. Berdasarkan pengamatan A1 mempunyai pH 7, Homogenitas. Dari hasil uji laboratorium di LPPT UGM Yogyakarta untuk uji mutu dengan mengambil sampel, tinggi busa dan bilangan penyabunan 18,34 cm.

Saran

1. Perlu dilakukan upaya untuk menyebarluaskan informasi tentang Diava anti ketombe dengan daun jambu biji (*Psidium guajava L*) melalui organisasi yang ada di masyarakat.
2. Penelitian Diava anti ketombe selanjutnya diharapkan mampu meneliti minyak yang terkandung didalamnya.

DAFTAR PUSTAKA

Arisandi, D., Indra, Z., & Kartini, K. (2021). Mengidentifikasi Hoax Pada Hasil Pencarian Berita Online Dengan Teknik Web Scraping Dan Algoritma C4.5. *Rabit : Jurnal Teknologi Dan Sistem Informasi Univrab*, *6*(2), 130–137. Https://Doi.Org/10.36341/Rabit.V6i2.690

Deviacita, D., A., Sasty, H., P., Muhardi, H., Profesor, J., Nawawi, D. H. H., Laut, B., Tenggara, P., Pontianak, K., & Barat, K. (2019). Implementasi Web Scraping Untuk Pengambilan Data Pada Situs Marketplace. *7*(4).

Fathir, Hariyadi, M. A., & Miftachul A, Y. (2023). Analisis Sentimen Artikel Berita Pemilu Berbasis Metode Klasifikasi. *Jurnal Indonesia : Manajemen Informatika Dan Komunikasi*, *4*(2), 485–493. Https://Doi.Org/10.35870/Jimik.V4i2.220

Fikri, M. R., Handayanto, R. T., & Irwan, D. (2022). Web Scraping Situs Berita Menggunakan Bahasa Pemrograman Python. *Journal Of Students' Research In Computer Science*, *3*(1), 123–136. Https://Doi.Org/10.31599/Jsrcs.V3i1.1514

Hari, E., Prastyo, A., Studi, P., & Wiratsongko, R. (2020). Implementasi Teknik Web Scraping Pada Situs Berita

Menggunakan Metode Supervised Learning.

Julianno, D., Noertjahyana, A., & Purbowo, A. N. (2020). Implementasi Web Scraping Untuk Pengumpulan Informasi Promo Makanan Menggunakan Klasifikasi Naïve Bayes.

Keputusan Dirjen Penguatan Riset Dan Pengembangan Ristek Dikti, S., Sahria, Y., & Hatta Fudholi, D. (2017). Analisis Topik Penelitian Kesehatan Di Indonesia Menggunakan Metode Topic Modelling Lda (Latent Dirichlet Allocation). *1*(3), 336–344.

Satriajati, S., Bagus Panuntun, S., & Pramana, S. (2020). Implementasi Web Scraping Dalam Pengumpulan Berita Kriminal Pada Masa Pandemi Covid-19.

Sembiring, F., Yudistyral, D., Sari, D. P., Sistem Informasi, P., Pendidikan, P., Dan, S., & Informasi, T. (2020). Penerapan Teknik Scraping Python Pada Website Marketplace Indonesia. *2*(1), 15–22.

Zhao, B. (2017). Web Scraping. In *Encyclopedia Of Big Data* (Pp. 1–3). Springer International Publishing. Https://Doi.Org/10.1007/978-3-319-32001-4_483-1